AI 에이전트 미니 프로젝트

반도체 기술 전략 분석 보고서 자동 생성 AI 에이전트 시스템

SECTION 1. Workflow 설계

1-1. Goal — 프로젝트 목표

HBM4, PIM, CXL 등 최신 반도체 R&D 정보를 AI 에이전트가 자동 수집·분석하고, R&D 담당자가 즉시 활용 가능한 기술 전략 분석 보고서를 자동 생성하는 시스템을 설계한다.

구분	내용
분석 기술	HBM4, PIM, CXL 등 최신 반도체 R&D
분석 관점	경쟁사별 기술 성숙도(TRL) 및 위협 수준
최종 산출물	R&D 담당자 즉시 활용 가능한 기술 전략 분석 보고서 (PDF)
분석 대상	SK하이닉스 · 삼성전자 · Micron 등 반도체사

1-2. Success Criteria — 성공 기준

기준	세부 내용	측정 방법
정보 커버리지	HBM4 · PIM · CXL 요청 기술 모두 포함	섹션별 키워드 체크
경쟁사 완성도	경쟁사 별 TRL 분석 포함	기업명 포함 여부
최신성	분야 별 각각 정의 (HBM4 180일 / PIM·CXL 365일 / 표준 730일)	문서 날짜 기준
TRL 근거 명시	TRL 추정 근거 명시 및 한계 작성	보고서 내 표기 여부
Human-in-the-Loop	Draft 통과 후 human review 승인/수정 분기 동작	워크플로우 동작 확인
Retrieval 성능	Hit Rate@5 ≥ 0.75, MRR ≥ 0.65, Citation count ≥ 4 (이 부분은 Hit Rate@5 ≥ 0.75, MRR ≥ 0.65, Citation count ≥ 4 기준으로 돌려보고, 확인된 결과 기준으로 작성하겠습니다.)	평가 스크립트 실행

1-3. Task — 수행 과제

- PDF 논문 수집 및 RAG 인덱스 구축 (query transformation → retrieval → evidence extraction)
- 웹 검색을 통한 최신 기업 동향 및 IR 자료 수집 (다각도 쿼리 + 확증 편향 방지)
- 수집 정보 기반 TRL 점수 산출 및 경쟁사 비교 분석 (Analysis Agent)
- 보고서 초안 작성 및 Human-in-the-Loop 검토 분기
- 승인된 초안 기반 PDF 최종 보고서 자동 생성

1-4. Control Strategy — 제어 전략

전략 항목	수정 반영 내용
아키텍처	Supervisor 패턴 — 모든 라우팅과 종료 여부는 Supervisor가 단독 결정
LLM Judge	RAG / Web Search / Analysis / Draft Generation / PDF Generation Agent는 내부 마지막 단계에서 judge 결과를 반환
Threshold 판정	Supervisor는 각 agent_judge_result를 config.thresholds[agent]와 비교하여 approve / retry / fail 판정
재시도 제어	retry 시 Supervisor가 retry_reason과 improvement_instructions를 state에 기록하고 같은 Agent를 재호출
재시도 반영 방식	RAG / Web Search는 query transformation node가 feedback을 반영하고, Draft Generation은 report writing node가 Supervisor 또는 human feedback을 반영
Human-in-the-Loop	Draft Generation Agent가 threshold를 통과한 뒤에만 human review node로 이동
Human Reject 처리	human이 reject하면 human_feedback을 state에 저장한 뒤 Draft Generation Agent 재호출
종료 조건	최종 pdf_path 생성 이후에도 END 판정은 Supervisor만 수행

1-5. Structure — 에이전트 구성

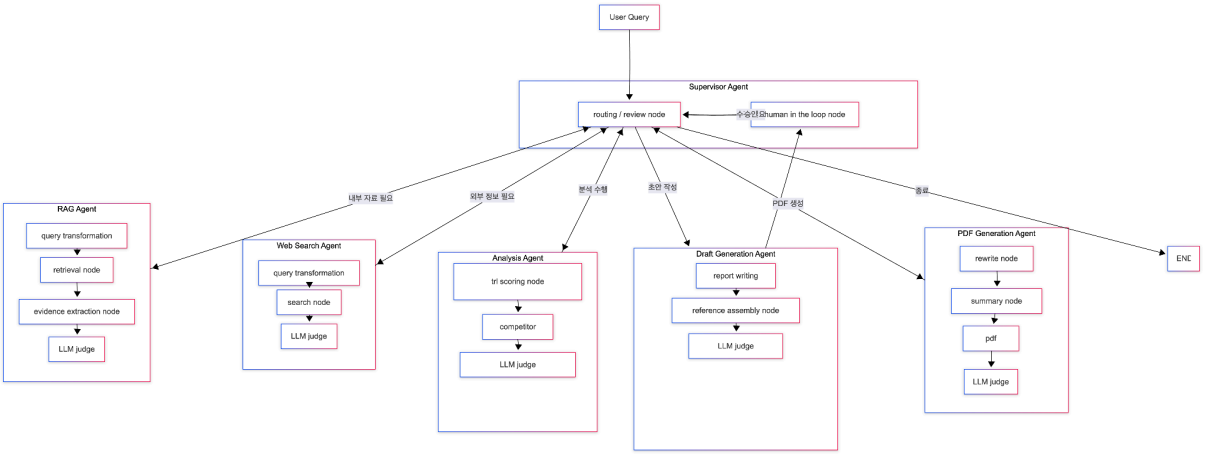

에이전트	주요 역할	내부 노드 수	마지막 단계 산출
Supervisor Agent	라우팅 · threshold 판정 / human review 관리 · 종료 결정	2개	—
RAG Agent	내부 자료 검색 · 증거 추출	4개	LLM judge 결과

Web Search Agent	외부 정보 수집 · 편향 방지	3개	LLM judge 결과
Analysis Agent	TRL 점수 산출 · 경쟁사 비교	3개	LLM judge 결과
Draft Generation Agent	보고서 초안 작성 · 참고문헌 정리	3개	LLM judge 결과
PDF Generation Agent	승인 초안 기반 PDF 렌더링	3개	LLM judge 결과

SECTION 2. 개별 에이전트 정의

2-1. Supervisor Agent

항목	내용
역할	전체 워크플로우 조율 · 에이전트 라우팅 · threshold 판정 / Human-in-the-Loop 관리 · 종료 판단
입력	AgentState 전체 + config.thresholds + human_decision / human_feedback
출력	다음 실행 에이전트 이름(status) 또는 END
사용 모델	GPT-4o-mini (temperature=0, JSON mode)

내부 노드 구성

SR

SR — routing / threshold decision node

각 Agent가 반환한 judge 결과(score, verdict, issues, suggestions)를 읽고 config threshold와 비교하여 approve / retry / fail을 결정한다. retry일 경우 retry_reason, improvement_instructions를 state에 저장한 뒤 동일 Agent를 재호출한다.

ST

ST — terminating/human in the loop node

Draft Generation Agent가 threshold를 통과하면 활성화된다. 사람은 approve 또는 reject를 선택한다. approve 결과는 Supervisor로 되돌아와 PDF Generation Agent 호출에 사용되고, reject 결과는 human_feedback과 함께 Supervisor에 전달되어 Draft Generation Agent 재시도에 사용된다.

중요 규칙**: END** 판정은 **Supervisor**만 내린다**. human approval, PDF** 생성 성공**,** 각 **Agent pass** 모두 종료를 직접 실행하지 않고 반드시 **Supervisor**를 거친다**.**

라우팅 규칙 요약

- Supervisor가 가장 먼저 RAG Agent 호출
- 각 Agent 실행 후에는 항상 Supervisor로 복귀
- Supervisor는 해당 Agent의 judge_result.score와 config threshold를 비교
- approve이면 다음 단계로 진행, retry이면 같은 Agent 재호출, fail이면 종료 또는 예외 처리
- Draft Generation Agent가 threshold를 통과하면 human review로 이동
- human approve이면 Supervisor가 PDF Generation Agent 호출
- human reject이면 human_feedback 저장 후 Supervisor가 Draft Generation Agent 재호출
- PDF Generation Agent가 threshold를 통과하고 pdf_path가 유효하면 Supervisor가 END 결정

2-2. RAG Agent

항목	내용
역할	내부 PDF 자료 검색, 쿼리 변환, 증거 추출, 품질 검증
입력	query, supplement_queries, retry_reason, improvement_instructions
출력	rag_retrieved, normalized_evidence, rag_judge_result
임베딩 모델	bge-m3 (오픈소스, 로컬 실행)
검색 방식	Hybrid Search (FAISS Dense 0.5 + BM25 Sparse 0.5)
VLM 활용	PDF 내 차트·다이어그램 이미지 → GPT-4o Vision 분석

내부 노드 구성 **(R1 → R2 → R3 → R4)**

R1

R1 — query transformation

원본 쿼리를 RAG 검색에 최적화된 형태로 변환한다. 재시도 시에는 Supervisor가 남긴 improvement_instructions와 retry_reason을 반영하여 누락 기업·기술·기간 조건을 보강한 새로운 검색 쿼리를 작성한다.

R2

R2 — retrieval node

변환된 쿼리로 FAISS + BM25 하이브리드 검색을 실행한다. 기술별 최신성 기준(HBM4: 180일, PIM/CXL: 365일)을 검토하고 상위 K개 문서를 반환한다.

R3

R3 — evidence extraction node

검색 문서에서 TRL 추정 근거·수치·기업명을 추출하고 PDF 이미지 분석 결과를 포함해 normalized_evidence를 만든다.

R4

R4 — LLM judge

양적 커버리지, 최신성, 근거 명확성, 기업·기술 매핑, 인용 가능성, 구조 완결성을 평가한 뒤 judge 결과(score, pass 여부, retry 필요 사유, 개선 지시)를 반환한다. 판단 자체는 여기서 끝나며 approve/retry/fail 결정은 Supervisor가 수행한다.

2-3. Web Search Agent

항목	내용
역할	최신 외부 정보 수집, 다각도 쿼리 생성, 확증 편향 방지, 출처 분류
입력	query, supplement_queries, retry_reason, improvement_instructions
출력	web_queries, web_classified, web_judge_result
검색 도구	Tavily API
수집 대상	기업 IR · 공식 뉴스룸 · IEEE 논문 · TrendForce · Hot Chips 발표 등

내부 노드 구성 **(W1 → W2 → W3)**

W1

W1 — query transformation

원본 쿼리를 최신 동향, 기술 한계, 경쟁사 비교, 특허·채용 간접 지표, 상용화 일정의 5가지 관점으로 다양화한다. 재시도 시에는 Supervisor feedback을 반영해 누락 관점 또는 편향 보정 관점을 추가한다.

W2

W2 — search node

다양화된 쿼리로 멀티 도메인 검색을 수행한다. 허용 도메인과 출처 유형별 TRL 구간 태깅 규칙을 적용해 결과를 구조화한다.

W3

W3 — LLM judge

수집 결과의 출처 편향, 최신성 부족, 기업 누락, 관련성 부족 여부를 평가하고 judge 결과(score, issues, improvement_instructions)를 반환한다. retry 여부는 Supervisor가 threshold와 비교해 최종 판정한다.

2-4. Analysis Agent

항목	내용
역할	수집된 근거 기반 TRL 점수 산출, 경쟁사별 기술 성숙도 비교 분석
입력	normalized_evidence, retry_reason, improvement_instructions
출력	trl_scores, competitor_analysis, analysis_judge_result
사용 모델	GPT-4o (temperature=0, JSON mode — 분석 일관성 최우선)
TRL 기준	NASA 9단계 TRL 기준 적용, TRL 4~6은 간접 지표 기반 추정으로 명시

내부 노드 구성 **(A1 → A2 → A3)**

A1

A1 — trl scoring node

수집 근거를 기반으로 기업별·기술별 TRL 점수를 산출한다. 재시도 시에는 Supervisor가 지정한 기업·기술 조합, 근거 보강 포인트, 추정 근거 표현 방식을 반영한다.

A2

A2 — competitor comparison node

3사 × 3기술 TRL 비교 매트릭스와 위협 수준, 공백 기술 영역을 정리한다.

A3

A3 — LLM judge

TRL 점수 근거의 논리적 일관성, 기업 간 격차 설명력, 누락 항목 여부를 평가해 judge 결과를 반환한다. threshold 미달이면 Supervisor가 Analysis Agent 재시도 또는 상위 단계 보강을 지시한다.

2-5. Draft Generation Agent

항목	내용
역할	Analysis Agent 결과 기반 보고서 각 섹션 작성 및 참고문헌 조합
입력	trl_scores, competitor_analysis, normalized_evidence, retry_reason, improvement_instructions, human_feedback
출력	sections, draft, references, draft_judge_result
사용 모델	GPT-4o (temperature=0.3 — 전문 보고서 문체)
재시도	Supervisor feedback 또는 human feedback을 반영해 같은 Agent 내 report writing node를 다시 수행

내부 노드 구성 **(D1 → D2 → D3)**

D1

D1 — report writing node

SUMMARY / 분석 배경 / 기술 현황 / 경쟁사 동향 / 전략적 시사점의 5개 섹션을 작성한다. retry 시에는 Supervisor feedback 또는 human_feedback을 반영하며, 필요한 경우 특정 섹션만 선택적으로 재작성한다.

D2

D2 — reference assembly node

사용된 모든 출처를 수집·정리하여 REFERENCE 섹션을 구성한다.

D3

D3 — LLM judge

SUMMARY 포함 여부, 3사 모두 분석 여부, TRL 추정 명시 여부, REFERENCE 포함 여부, 서술 일관성을 점검하고 draft_judge_result를 반환한다. score가 threshold 이상이면 Supervisor가 human review로 라우팅한다.

주의: **Draft Generation Agent**가 **threshold**를 통과하기 전에는 **human review**로 이동하지 않는다.

2-6. PDF Generation Agent

항목	내용
역할	승인된 초안을 시각화 포함 PDF로 렌더링
입력	sections, trl_scores, competitor_analysis, references, retry_reason, improvement_instructions
출력	pdf_path, pdf_judge_result
사용 모델	GPT-4o (Chart Renderer — matplotlib 코드 자동 생성)
라이브러리	reportlab, matplotlib, PyMuPDF

내부 노드 구성 **(P1 → P2 → P3)**

P1

P1 — summary node

EXECUTIVE SUMMARY 페이지와 핵심 표·차트를 구성한다.

P2

P2 — pdf rendering node

전체 섹션을 A4 레이아웃으로 조합하고 한글 폰트, 각주, 표·차트를 배치한다.

P3

P3 — LLM judge

생성된 PDF의 구조 적정성, 차트 렌더링 오류, 섹션 누락 여부를 점검해 judge 결과를 반환한다.
pdf_path 생성 성공 여부와 score를 Supervisor가 확인한 뒤 END를 결정한다.

TRL 추정 기준표

TRL 구간	공개 여부	주요 근거 소스	신뢰도
TRL 1~3 (기초연구)	대부분 공개	논문, 학회 발표, 특허 출원	높음
TRL 4~6 (개발·검증)	영업 비밀 영역 많음	채용공고 키워드, 학회 발표 빈도, 간접 지표	중간 (추정)
TRL 7~9 (양산·상용화)	일부 공개	IR 공시, 양산 발표, 샘플 공급 발표	높음

SECTION 3. Agent State & Graph 흐름

3-1. Agent State 정의

필드명	생성 주체	설명
query	User	사용자 분석 쿼리
supplement_queries	Supervisor	보강 쿼리 목록
web_queries	Web Agent / W1	다양화된 검색 쿼리 목록
rag_retrieved	RAG Agent / R2	하이브리드 검색 결과 문서
normalized_evidence	RAG Agent / R3	Web + RAG 통합 정규화 근거
web_classified	Web Agent / W2	출처 유형 + TRL 구간 태깅된 웹 검색 결과
trl_scores	Analysis Agent / A1	기업 × 기술별 TRL 점수표
competitor_analysis	Analysis Agent / A2	3사 비교 매트릭스 + 위협 수준
sections	Draft Agent / D1	보고서 섹션별 텍스트
references	Draft Agent / D2	참고문헌 목록
draft	Draft Agent / D1~D3	보고서 초안 전체

pdf_path	PDF Agent / P2	최종 PDF 파일 경로
rag_judge_result	RAG Agent / R4	RAG judge score, issues, suggestions
web_judge_result	Web Agent / W3	Web judge score, bias flags, suggestions
analysis_judge_result	Analysis Agent / A3	Analysis judge score, inconsistency notes
draft_judge_result	Draft Agent / D3	Draft judge score, section completeness notes
pdf_judge_result	PDF Agent / P3	PDF judge score, rendering validation notes
retry_reason	Supervisor	같은 Agent 재시도 사유
improvement_instructions	Supervisor	재시도 시 해당 Agent가 반영해야 할 개선 지시
human_feedback	Human review	human reject 시 수정 요청 내용
human_decision	Human review	approve / reject 결과
revision_count	Supervisor 또는 Agent	Agent별 재시도 횟수 추적
status	Supervisor	다음 실행 에이전트 이름

3-2. Graph 흐름

단계	From	조건	To
1	START	진입점	Supervisor (SR)
2	Supervisor	normalized_evidence 없음	RAG Agent
3	RAG Agent	R4에서 rag_judge_result 반환	Supervisor
4	Supervisor	rag_judge_result < rag_threshold	RAG Agent 재시도
5	Supervisor	RAG approve + 외부 최신 정보 필요	Web Search Agent
6	Web Search Agent	W3에서 web_judge_result 반환	Supervisor
7	Supervisor	web_judge_result < web_threshold	Web Search Agent 재시도
8	Supervisor	evidence 충분 + trl_scores 없음	Analysis Agent
9	Analysis Agent	A3에서 analysis_judge_result 반환	Supervisor
10	Supervisor	analysis_judge_result < analysis_threshold	Analysis Agent 재시도
11	Supervisor	trl_scores 있음 + draft 없음	Draft Generation Agent
12	Draft Agent	D3에서 draft_judge_result 반환	Supervisor
13	Supervisor	draft_judge_result < draft_threshold	Draft Generation Agent 재시도
14	Supervisor	draft_judge_result 통과	Human in the Loop
15	Human review	approve	Supervisor → PDF Generation Agent
16	Human review	reject	Supervisor → Draft Generation Agent
17	PDF Agent	P3에서 pdf_judge_result 반환	Supervisor
18	Supervisor	pdf_judge_result < pdf_threshold	PDF Generation Agent 재시도
19	Supervisor	pdf_path 유효 + PDF approve	END

3-3. Supervisor 의사결정

재시도 반영 규칙

- RAG / Web Search 재시도 시: query transformation node가 Supervisor feedback을 반영하여 쿼리를 다시 작성
- Draft Generation 재시도 시: report writing node가 Supervisor feedback 또는 human_feedback을 반영하여 초안을 다시 작성
- Human reject는 즉시 END가 아니라 Draft Agent 재작성 트리거로만 사용

SECTION 4. 모델 및 기술 스택

구분	선정 모델	사용 노드	선정 이유
LLM (빠른 판단)	GPT-4o-mini	Supervisor SR · W1 · W3	반복 호출 최적화, 비용 효율
LLM (분석·작성)	GPT-4o	A1 · A2 · D1 · D2 · P1 · P2	전문 분석 품질, 장문 컨텍스트 대응
VLM (이미지)	GPT-4o Vision	R3	PDF 차트·다이어그램 해석 후 csv 로 변환 및 메타데이터 생성하여 RAG에 활용
임베딩	bge-m3	R2	한·영 혼용 검색 성능, 비용 효율

4-2. Retrieval 설계

항목	선정	이유
검색 방식	Hybrid (FAISS Dense + BM25)	의미 검색과 키워드 정확 매칭이 모두 필요
앙상블 가중치	Dense 0.5 : BM25 0.5	두 방식의 균형 반영
최신성 기준	HBM4 180일 / PIM·CXL 365일 / 표준 730일	기술별 발전 속도 반영
평가 지표	Hit Rate@5, MRR, Citation count	README 및 평가 보고서에 기록
판정 방식	Agent judge 결과 + Supervisor threshold	성능과 품질을 분리해 통제 가능

SECTION 5. 기술 전략 분석 보고서 목차 (초안)

SUMMARY — 핵심 내용 요약 (1/2 페이지 이내)

- 전체 분석 결론 3줄 요약
- 경쟁사별 최고 위협 기술 한눈에 보기
- 즉시 대응 필요 R&D 과제 Top 3

1. 분석 배경

- 1.1 왜 지금 이 기술을 분석해야 하는가
- 1.2 AI 인프라 확대와 메모리 반도체 수요 동향
- 1.3 분석 범위 및 방법론 (TRL 기반 평가 기준 설명)
- 1.4 데이터 수집 출처 및 한계 (TRL 4~6 추정 구간 명시)

2. 분석 대상 기술 현황

- 2.1 HBM4 현황 — 기술 정의, 주요 스펙, 양산 로드맵
- 2.2 PIM 현황 — 기술 정의, 메모리 월 해결 방향, 상용 제품 현황
- 2.3 CXL 현황 — 메모리 풀링 아키텍처, 버전별 진화, 상용화 현황

3. 경쟁사 동향 분석

- 3.1 SK하이닉스 — 기술별 TRL 평가, 최신 발표, 위협 수준
- 3.2 삼성전자 — 기술별 TRL 평가, 최신 발표, 위협 수준
- 3.3 Micron — 기술별 TRL 평가, 최신 발표, 위협 수준
- 3.4 경쟁사 종합 비교 — 기술별 TRL 비교 매트릭스 및 위협 히트맵

4. 전략적 시사점

- 4.1 R&D 우선순위 관점 대응 방향
- 4.2 단기(6개월) · 중기(1~2년) · 장기(3년+) 과제
- 4.3 리스크 시나리오 및 대응 전략

REFERENCE

- 논문 · 학회 발표 (IEEE, Hot Chips, ISSCC 등)
- 기업 IR · 공식 보도자료
- 시장조사 자료 (TrendForce, SemiAnalysis 등)
- 특허 · 표준 문서 (JEDEC, USPTO 등)

부록 제안

- 실험 로그 / 평가 스크립트 결과 캡처